

**UNIVERSIDADE DO VALE DO RIO DOS SINOS - UNISINOS**  
**UNIDADE ACADÊMICA DE GRADUAÇÃO**  
**CURSO DE SISTEMAS DE INFORMAÇÃO**

**BRUNO GABRIEL DE OLIVEIRA**

**REDES NEURAIS LONG-SHORT TERM MEMORY (LSTM) E A TEORIA  
MODERNA DO PORTFÓLIO PARA GESTÃO DE CARTEIRAS DE  
INVESTIMENTOS**

**São Leopoldo**  
**2022**

BRUNO GABRIEL DE OLIVEIRA

**REDES NEURAIS LONG-SHORT TERM MEMORY (LSTM) E A TEORIA  
MODERNA DO PORTFÓLIO PARA GESTÃO DE CARTEIRAS DE  
INVESTIMENTOS**

Artigo apresentado como requisito para  
obtenção do título de Bacharel pelo Curso  
de Sistemas de Informação da  
Universidade do Vale do Rio dos Sinos  
(UNISINOS).

Orientador: Prof. Dr. João Ricardo Bittencourt

São Leopoldo

2022

## REDES NEURAIS LONG-SHORT TERM MEMORY (LSTM) E A TEORIA MODERNA DO PORTFÓLIO PARA GESTÃO DE CARTEIRAS DE INVESTIMENTOS

Bruno Gabriel de Oliveira<sup>1</sup>

João Ricardo Bittencourt<sup>2</sup>

**Resumo:** Entre os principais trabalhos voltados para a compreensão sobre alocação de investimento eficiente no mercado acionário podemos citar o chamado portfolio selection (Teoria Moderna do Portfólio), proposta pelo economista norte americano Harry Markowitz em 1950 que propôs o modelo intitulado média-variância, servindo de base matemática para a correta alocação de recursos entre diversos ativos em uma carteira de investimentos, tendo por objetivo a redução dos riscos e otimização dos retornos. Nos últimos anos, com o avanço computacional na área de análise e processamento de dados, bem como, tecnologias de aprendizado de máquina e inteligência artificial, proporcionaram a utilização de algoritmos inteligentes para a predição futura da série histórica de preços de ações no mercado acionário. Desta forma, este trabalho de pesquisa apresenta o desenvolvimento de uma rede neural artificial recorrente Long-short Term Memory (LSTM) aplicada a predição futura da taxa de retorno semanal do preço de fechamento individual de 10 ações de empresas do mercado acionário brasileiro que compõem uma carteira de investimentos hipotética, tendo como objetivo aplicar o modelo média-variância proposto por Markowitz aos dados preditos, a fim de, maximizar os retornos do investimento, minimizando os riscos. Ao fim do estudo, aplicando o modelo de Markovitz ao último ano de negociação dos ativos da carteira (01/04/21 à 31/03/22), observou-se um retorno anual de -16,8% e volatilidade de 22,7%, resultados inferiores ao retorno de -12,1% e volatilidade de 19,2% constatada para a mesma carteira onde o capital investido em cada ativo foi aplicado igualmente. Assim, verificou-se pouca efetividade em se aplicar a teoria moderna do portfólio para dados preditos semanalmente através de modelos de Machine Learning (ML), pois, do ponto de vista prático para o investidor comum, uma estratégia simples de alocação de capital igual entre todos os ativos de uma carteira, seria o suficiente para lhe conferir uma relação retorno/risco no longo prazo aceitáveis.

**Palavras-chave:** Redes Neurais Artificiais; Teoria moderna do portfólio; Aprendizado de máquina.

### 1 INTRODUÇÃO

Os mercados de capitais têm papel de extrema importância no processo de desenvolvimento econômico, pois é o maior fornecedor de recursos para a economia.

---

<sup>1</sup> Graduando do curso superior de Bacharelado em Sistemas de Informação da Universidade do Vale do Rio dos Sinos – UNISINOS. E-mail: brunogabrieldeoliveira@gmail.com

<sup>2</sup> Professor(a) orientador(a) Dr. João Ricardo de Bittencourt Menezes. E-mail: joaorb@unisinos.br

(LUND; SOUZA; CARVALHO, 2014). O avanço das tecnologias de armazenamento de dados observado nos últimos anos viabilizou a análise histórica dos dados de ações. (MESQUITA, 2019). Assim, observou-se um natural estímulo a busca por modelos baseado em dados, destacando-se as redes neurais artificiais (RNA). (MARTINS; METTE; MACEDO, 2008).

Neste contexto, redes neurais recorrentes LSTM (*Long-Short Term Memory*) vem sendo especialmente utilizadas na construção de modelos de *machine learning* para predição, pois conforme observa Dametto (2018, p. 37), “[...] redes neurais LSTM são capazes de armazenar informações por longos períodos ao processar uma sequência”. Ainda no campo de finanças, o modelo denominado média-variância proposto por Harry Max Markowitz na década de 1950, busca a chamada fronteira eficiente, um limiar ou relação, onde carteiras de investimentos tendem a apresentar o maior retorno médio possível para cada nível de risco. (RUBIM, 2019).

O objetivo deste trabalho de pesquisa visa a construção de um modelo de rede neural artificial recorrente LSTM para a predição futura semanal de uma carteira de investimentos hipotética composta por ações de empresas brasileiras listadas na B3, a bolsa de valores do Brasil. Aplicando-se a teoria moderna do portfólio aos dados preditos pela rede neural LSTM, busca-se a fronteira eficiente, onde a alocação de capital eficaz entre os ativos é dada a fim de maximizar o retorno da carteira para os preços preditos, aceitando o menor risco possível.

O capítulo 2 apresenta o referencial teórico da pesquisa, onde temas como a teoria do portfólio e inteligência artificial são aprofundados. O capítulo 3 apresenta os métodos e tecnologias utilizadas para o desenvolvimento da pesquisa, como a coleta e tratamento de dados, construção dos modelos de ML e configuração da rede LSTM. Por sua vez, o capítulo 4 informa os resultados obtidos após a construção e testes da rede neural, comparando as diferentes estratégias de investimento utilizando os algoritmos de predição ou não.

O capítulo 5 apresenta uma análise dos resultados encontrados durante o capítulo anterior, apresentando mais detalhadamente o comportamento dos modelos treinados e observados. Por fim, o capítulo 6 apresenta uma conclusão para os resultados obtidos, demonstrando a efetividade das estratégias pesquisadas, sugerindo pontos de melhorias no estudo e desenvolvimento dos modelos de ML.

## 1.1 Problema

A natureza volátil do mercado financeiro apresenta um grande desafio para o processo de compra e venda de ativos. (MESQUITA, 2019). Desta forma, redes neurais artificiais vêm ganhando importância no campo da econometria para tarefas de previsão futura dos preços dos ativos (MARTINS; METTE; MACEDO, 2008), visto que possuem a capacidade de analisar dados após a abstração de suas distorções e ruídos, possibilitando a extração de relações não-lineares entre as variáveis preditas. (ELLER, 2020).

Porém, dado a volatilidade inerente do mercado financeiro, novas informações de caráter aleatório tendem a ocorrer no futuro, fugindo aos padrões preditos pelos modelos de *machine learning* desenvolvidos com base em dados passados das séries históricas, desta forma, o correto balanceamento dos pesos dos ativos da carteira de investimento proposto pela teoria moderna do portfólio de Markowitz (1952) pode servir como proteção adicional às oscilações de preço, visto que, a carteira mais eficiente, respeitando a relação retorno/risco, é configurada.

Assim, o presente estudo trabalha com a premissa de que, além da predição da variação futura da carteira de investimentos dada pelo modelo de *machine learning*, esperando-se um grau de acurácia satisfatório, seria necessário ainda o correto balanceamento dos ativos da carteira predita, a fim de, potencializar o possível retorno futuro, mitigando ao máximo os riscos incorridos, visto que, o fator de aleatoriedade que foge a predição não pode ser mensurado. Portanto, este trabalho de pesquisa tenta responder ao seguinte questionamento:

- Como o balanceamento eficiente de carteiras de investimentos em ações através da Teoria Moderna do Portfólio se comporta dado a variações de preço preditas por Redes Neurais Artificiais?

## 1.2 Objetivo geral

Propor um modelo de Rede Neural Artificial Recorrente *Long-short Term Memory* (LSTM) capaz de prever a variação futura semanal do preço individual de ações que compõem uma carteira de investimentos hipotética, a fim de, com base na Teoria Moderna do Portfólio proposta por Markowitz (1952), estimar eficientemente o

capital alocado para cada ativo, diminuindo os riscos de perda financeira da carteira como um todo, maximizando os retornos.

### 1.3 Objetivos específicos

- a) Modelar uma RNA do tipo recorrente LSTM capaz de prever a taxa de retorno futura semanal de cada ação de uma carteira de investimentos hipotética;
- b) Aplicar a teoria de Markowitz aos resultados futuros indicados pela rede neural LSTM para estimar o capital a ser aplicado em cada uma das ações da carteira, a fim de, obter a chamada “fronteira eficiente”;
- c) Comparar o risco e retorno financeiro do último ano de negociação para a carteira predita pela rede LSTM, balanceada pelo modelo de Markovitz, com a mesma carteira onde todos os ativos possuem o mesmo capital aplicado.

## 2 FUNDAMENTAÇÃO TEÓRICA

### 2.1 O mercado financeiro

O mercado financeiro é onde ocorre a negociação de ativos, como ações de empresas de capital aberto, mercadorias, câmbio e commodities, sendo parte vital de qualquer economia, pois a sua movimentação se traduz em oportunidades econômicas. (MATSUMOTO, 2019).

Para Dametto (2018, p. 17),

[...] o mercado de investimento é parte do sistema financeiro. Nele, um agente superavitário empresta o seu capital a um agente deficitário com o objetivo de compensação financeira. Este empréstimo ocorre por meio de uma instituição financeira, devidamente regularizada no sistema financeiro.

Lund, Souza e Carvalho (2014) explicam que, em todo o mundo, o mercado de capitais é uma forma de estimular o aumento da poupança interna e fornecer às empresas um instrumento adicional para captar recursos que financiem sua expansão.

### 2.1.1 A bolsa de valores do Brasil [B]3

A bolsa de valores do Brasil, também conhecida como [B]3 (alusão a bolsa, Brasil, balcão) é uma das principais empresas de infraestrutura de mercado financeiro do mundo, atuando em ambientes de bolsa e balcão, sendo também uma empresa de capital aberto negociando através do código B3SA3. (B3, 2021). Através das plataformas da B3, é ofertada a listagem das ações de livre negociação do mercado e demais ativos, além do registro, compensação, liquidação de compras e vendas realizadas por investidores, além de informações ao mercado. (INFOMONEY, 2021).

### 2.1.2 O processo de escolha no mercado financeiro

No mercado acionário antes de tomar uma decisão sobre investimentos, o investidor decisor, com base em seus conhecimentos adquiridos via estudos teóricos do mercado e experiências anteriores, avalia os cenários possíveis que a sua decisão resultará, avaliando os riscos e o possível retorno atrelado. Para Romani (2017, p. 4),

**Risco:** É a variação da rentabilidade de um investimento. Esta variação influencia na probabilidade de se obter um rendimento esperado. Quando há muita variação em sua rentabilidade, um investimento pode não trazer a rentabilidade esperada ou até trazer prejuízo.

**Rentabilidade:** É o retorno do capital investido, ou seja, se o investimento fosse retirado, subtraindo-se o capital após a retirada do capital inicialmente investido, teríamos a rentabilidade.

Para Dametto (2018), existem, basicamente, dois modelos diferentes utilizados para apoiar o investidor em sua estratégia de compra ou venda de ações, o modelo fundamentalista e o modelo técnico. Para Kerr (2011), o modelo fundamentalista tem por objetivo a análise da situação financeira da empresa e mercado, considerando elementos de natureza contábil como o balanço patrimonial e fluxo de caixa.

Já para Silva (2018), a análise técnica busca compreender as oscilações do mercado através da análise numérica e de gráficos, baseando-se em presos passados, além de dados como o volume de negociação.

### 2.1.3 Carteiras de investimentos

Uma carteira de investimento, também conhecida como cesta ou portfólio de ativos é a composição de todos os ativos financeiros que um investidor tem em sua propriedade, com o objetivo de rentabilizar seu capital. (PEREIRA, 2018). Após definir seus objetivos financeiros, o investidor deverá traçar a composição de ativos para a sua carteira de investimentos, conforme o seu perfil de investidor. O perfil de investidor é o processo no qual o investidor acaba por conhecer o quanto suporta de risco para suas aplicações e, segundo Aguillar (2020), deve considerar também outros fatores, como a sua renda, conhecimento sobre o mercado e o quanto deseja investir.

#### 2.1.4 Séries temporais financeiras

Uma série temporal é um conjunto de dados observados e organizados no tempo, onde a ordem das observações pode influenciar no resultado. (MASI; LOPES, 2009). Segundo Mesquita (2019), séries temporais são analisadas e observadas nas mais diversas áreas do conhecimento, valores diários de poluição, temperatura ou precipitação de chuvas, registros de marés, roubos de veículos são exemplos.

Existem fatores que influenciam no comportamento dos valores observados nas séries históricas, tanto para observações passadas quanto presentes. Desta forma, ao identificar e isolar tais fatores, seria possível realizar previsões de comportamento para os valores futuros das séries. (MASI; LOPES, 2009).

## 2.2 Teoria moderna do portfólio

A teoria do portfólio trata da relação que as variáveis risco e retorno têm sobre o comportamento de um portfólio, bem como, dos efeitos da diversificação dos ativos sobre a carteira. (MARKOWITZ, 1952). De acordo com Markowitz (1952) o investidor é avesso ao risco, ou seja, caso dois ativos possuam o mesmo retorno esperado, porém riscos diferentes, o investidor, inevitavelmente, escolherá o investimento de menor risco. Segundo Igarashi, Martioli e Igarashi (2019) à luz de Markowitz (1952), o retorno de um ativo é dado pela seguinte fórmula (Equação 1, p. 7):



Equação 1 - Retorno esperado de um ativo

$$\text{Retorno ação} = \frac{\text{Pesperado} - P_i}{P_i} \cdot 100$$

Fonte: Igarashi, Martioli e Igarashi (2019, p. 4360).

Onde ***Pi*** é o preço inicial do ativo a ser calculado em um dado período, e ***Pesperado*** é o retorno esperado para o período. Já o retorno esperado de um portfólio é calculado da seguinte forma:

Equação 2 - Retorno esperado de um portfólio

$$\text{Retorno}_{\text{portfólio}} = \sum_{i=1}^N W_i R_i$$

Fonte: Igarashi, Martioli e Igarashi (2019, p. 4360).

Na fórmula, ***N*** representa a quantidade de ativos que compõem a carteira de investimentos, ***Wi*** o peso de cada ativo no portfólio, desde que a soma de todos os pesos seja igual a 1 ou 100%, e ***Ri*** é o retorno esperado para cada ativo ***i***. A seguir calculamos a variância, ou risco do portfólio, uma vez que, sabemos calcular o retorno esperado. Conforme Costa (2015), de acordo com Braga (2008), tendo calculado retorno esperado de duas ações A e B, temos:

Equação 3 - Variância do retorno esperado do portfólio

$$\sigma_{\text{portfólio}}^2 = \underbrace{W_A^2 \sigma_A^2 + W_B^2 \sigma_B^2}_{\text{Riscos isolados}} + \underbrace{2W_A W_B \text{Cov}(AB)}_{\text{Riscos combinados}}$$

Fonte: Igarashi, Martioli e Igarashi (2019, p. 4360).

Markowitz, através de cálculos e modelos matemáticos, provou que o retorno de um portfólio não depende somente dos riscos e retornos individuais de cada um dos ativos, mas também da correlação que esses ativos apresentam entre si. (LEITE, 2020). Assim, a diversificação de ativos em uma carteira de investimentos melhora a sua eficiência, pois, na medida em que novos ativos são incorporados, o risco global é reduzido (desvio padrão), já o retorno é determinado pela ponderação dos retornos dos ativos individuais, de acordo com as suas correlações. (MOTA, 2017).

## 2.3 Inteligência artificial

A inteligência artificial (IA) é uma área da ciência da computação cujo objetivo é o desenvolvimento de computadores e sistemas que se comportam ou pensam de forma inteligente, desta forma, a IA estar relacionada com a Biologia, Lógica Matemática, Psicologia, Engenharia, Linguística, entre outros. (GOMES, 2010).

### 2.3.1 Aprendizado de máquina

O Aprendizado de Máquina (AM) é um ramo da ciência da computação, matemática e estatística voltada ao desenvolvimento de softwares e algoritmos capazes de reconhecer e extrair padrões de dados a fim de gerar novo conhecimento (DAMETTO, 2018). Para o autor (2018), o AM possui dois objetivos principais, o desempenho preditivo e a automação de processos de modelagem das bases de dados. Para buscar o desempenho preditivo sugerido por Dametto (2018) podemos analisar o que Vasco (2020) constata em seu trabalho, onde explica que uma base de dados bem planejada utilizada para o treinamento de uma rede neural tende a apresentar melhores resultados na identificação de padrões no conjunto de dados.


### 2.3.2 Redes neurais artificiais

Uma Rede Neural Artificial (RNA) é um sistema de inteligência desenvolvido e estruturado, conforme a dinâmica de funcionamento e processamento de dados do cérebro humano. (VILELA; PENEDO; PEREIRA; 2018). Assim, conforme explica Silva (2018), a fim de conseguirmos projetar RNAs artificiais possíveis de serem analisadas e simuladas, redes neurais biológicas devem ser estudadas, uma vez que, os sistemas nervosos são constituídos de milhares de células nervosas interconectadas, lidando de maneiras diferentes com sinais que recebem como entrada.

Para Medeiros (2019) o neurônio artificial (Figura 1 – B, p. 9) é uma estrutura lógico-matemática que busca simular o comportamento, funções e a forma de um neurônio biológico, assim, para Santana, Dantas e Loiola (2016), em analogia ao neurônio biológico (Figura 1 – A, p. 9), os dendritos seriam a representação das entradas, as sinapses (ligações com o corpo celular) representados pelos pesos

sinápticos, os estímulos determinados pela função de soma, e o limiar de disparo, pela função de transferência, ou função de ativação.

Figura 1 - Neurônio biológico (A) e artificial (B)



Fonte: Oliveira (2021), Soares e Silva (2011, p. 60).

Thiele (2015), à luz de Haykin (2008), define matematicamente um neurônio artificial através da equação a seguir:

Equação 4 - Representação matemática do neurônio artificial

$$y_k = \varphi (Soma_k + B_k)$$

$$Soma_k = \sum_{j=1}^m W_{kj} X_j$$


Fonte: Thiele (2015, p. 40).

Onde,  $x_1, x_2, \dots, x_m$ , são representados como o sinal de entrada;  $w_1, w_2, \dots, w_m$  são os pesos sinápticos;  $m$  é a quantidade de conexões que encontram o neurônio  $k$ ;  $j$  é o neurônio da camada anterior; **Soma** é a saída do produto das entradas do neurônio, ponderados por seus respectivos pesos sinápticos;  **$b_k$**  representa a função de bias, um sinal externo que tem por objetivo alterar a entrada da função de ativação;  $\varphi(\cdot)$  é a função de ativação que dispara uma saída padronizada; e  **$y_k$** , por fim, representa a saída do neurônio  $k$ . (THIELE, 2015).

Em seu trabalho, Silva (2018) indica que uma rede neural pode ser dividida em três partes distintas: camada de entrada, camada oculta e camada de saída. A camada de entrada é a responsável por receber as informações, ou estímulos externos; A camada intermediária, ou oculta, recebe as informações da camada de entrada e processa a maior parte das informações, e; A camada de saída é

responsável por exibir o processamento da rede neural. A seguir (Figura 2) é apresentado um exemplo de rede neural multicamadas, conforme Silva (2018).

Figura 2 - Rede neural artificial



Fonte: Silva (2018, p. 28).

### 2.3.3 Redes neurais recorrentes

Redes Neurais Recorrentes (RNR) possuem ao menos um looping de retroalimentação, possibilitando que um sinal retorne para uma camada anterior, dificultando o treinamento, porém, especializando a rede neural para trabalhar com certos tipos de aplicação, como dados sequenciais. (VASCO, 2020). Diferentemente de Redes Neurais *Feedforward*, a informação não percorre um único sentido, não depende somente da informação corrente, mas também das entradas anteriores, assim há a possibilidade de existência de uma memória de curto prazo para rede. (NELSON, 2017).


### 2.3.4 Redes neural recorrente *long-short term memory* (LSTM)

Redes LSTM também possuem características de retroalimentação de informações atreladas em sua estrutura, porém, o grau de complexidade é mais elevado. (MATSUMOTO, 2019; DAMETTO, 2018). Para Matsumoto (2019), seu principal diferencial é a introdução de portões, ou *gates*, com a propriedade de adicionar ou remover informações ao estado do neurônio.

Rubim (2019) explica que redes neurais LSTM possuem uma configuração específica de neurônios que interagem entre si de forma recursiva, controlando o fluxo

de dados que fluem pelo sistema através da abertura ou fechamento dos portões de controle (*gates*) presentes nestas células. De acordo com o autor (2019, p. 67, grifo nosso), "[...] na formulação padrão são observados os seguintes elementos: **input gate**, **forget gate** e **output gate**, sendo cada um responsável pela execução de um controle específico".

Figura 3 - Neurônio ou célula LSTM



Fonte: Passos (2020, p. 31).

As equações de uma célula LSTM podem ser apresentadas conforme a seguir (Equação 5), onde o estado da célula é dado por ***ct***; A camada de saída *hidden state* por ***ht***; *Input gate* por ***It***; *output gate* por ***Ot*** e *forget gate* por ***Ft***. (VASCO, 2020).

Equação 5 - Equações célula LSTM

$$\begin{aligned}
 I_t &= \sigma(W_{xi}X_t + W_{hi}h_{t-1} + W_{ci}c_{t-1} + b_i) \\
 F_t &= \sigma(W_{xf}X_t + W_{hf}h_{t-1} + W_{cf}c_{t-1} + b_f) \\
 c_t &= F_t \cdot c_{t-1} + I_t \cdot \tanh(W_{xc}X_t + W_{hc}h_{t-1} + b_c) \\
 O_t &= \sigma(W_{xo}X_t + W_{ho}h_{t-1} + W_{co}c_{t-1} + b_o) \\
 h_t &= O_t \cdot \tanh(c_t)
 \end{aligned}$$

Fonte: Vasco (2020, p. 25).

Observando a Figura 3, o estado da célula é indicado pela linha horizontal que atravessa inteira, transferindo os dados da célula anterior para a corrente, e assim sucessivamente. O *forget gate* salva ou não a informação no estado da célula através de uma multiplicação elemento a elemento. Uma camada *sigmóide* e tangente hiperbólica compõe o *input gate* que farão parte do estado da célula e por fim, o *output*

*gate* forma a saída da célula através de uma multiplicação elemento a elemento com a tangente hiperbólica. (VASCO, 2020).

### 2.3.5 Funções de ativação

Para Mendonça (2019, p. 12), "[...] a função de ativação é a transformação não linear que aplicamos sobre o sinal de entrada. Essa saída transformada é então enviada para a próxima camada de neurônios como entrada". De acordo com Vasco (2020), Romani (2017) e Thiele (2015), pelo fato de os dados gerados no mercado financeiro tenderem a apresentar comportamento não-linear, funções de ativação com a mesma premissa seriam mais apropriadas, assim como as funções sigmóide e tangente hiperbólica (Equação 6).

Equação 6 - Funções de ativação sigmóide e tangente hiperbólica

$$\varphi(v_j) = \frac{1}{1+\exp^{-v_j}} \quad \varphi(v_j) = \tanh(v_j)$$

Fonte: Thiele (2015, p. 44).

Para a função sigmóide, primeira equação indicada acima, "[...]  $v_j$  é a soma ponderada das entradas sinápticas do neurônio  $j$ ". (THIELE, 2015, p. 44). Já a função tangente hiperbólica, segunda equação, "[...]  $v_j$  é o valor da soma ponderada das entradas sinápticas do neurônio  $j$ ". (THIELE, 2015, p. 45). Conforme Mendonça (2019) e Thiele (2015), a saída sigmóide resultará em um valor entre os intervalos de 0 e 1, assim, como a probabilidade de algum evento ocorrer limitasse a este valor, sigmóide é muito utilizada para a formulação de modelos onde o interesse pela probabilidade de certos eventos ocorrer, é almejado. Já a função tangente hiperbólica ( $\tanh$ ) tem seu valor centrado em zero, variando de -1 a 1. (MENDONÇA, 2019).

### 2.3.6 Erro quadrático médio (EQM)

O erro quadrático médio (EQM) ou *mean square error* (MSE) é uma medida de comparação quantitativa entre dois valores analisados que fornece uma descrição sobre o grau de semelhança ou diferença entre os valores observados. (THIELE, 2015). Segundo Passos (2020) a partir de Goodfellow (2016), o erro quadrático médio

é uma das funções de custo mais empregadas na avaliação de modelos de predição por redes neurais.

Equação 7 - Erro quadrático médio (EQM)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - x_i)^2$$

Fonte: Passos (2020, p.33).

Onde ***Y<sub>i</sub>*** indica o dado previsto; ***X<sub>i</sub>*** o dado verdadeiro (rótulo) e ***N*** o número total de dados ou previsões.

### 3 MATERIAIS E MÉTODOS

Para o desenvolvimento do projeto de pesquisa a metodologia quantitativa foi adotada, pois conforme Azevedo, Machado e Silva (2011) à luz de Roesch (2009), o método possibilita a elaboração de sumários, comparações e generalizações através de dados padronizados, assim, os dados serão analisados sob a perspectiva lógica, matemática e estatística, uma vez que, a intenção da pesquisa implica a mensuração de relações entre variáveis. Para Gil (2007), a pesquisa quantitativa é empregada quando as medidas quantificáveis de variáveis e suas interações são almejadas, pois utilizam medidas numéricas para avaliar e testar hipóteses e dados científicos.

#### 3.1 Linguagem de programação e algoritmos

Para a codificação da rede neural LSTM, coleta e tratamento de dados históricos, bem como análise e testes das estratégias estudadas, foi utilizada a linguagem de programação *Python*, além da IDE do *Spyder*. De acordo com Roveda (2020), *Python* é uma linguagem de alto nível, multiplataforma, modular, dinâmica, interpretada e orientada a objetos, onde os procedimentos estão inseridos em classes, possibilitando melhor controle e confiabilidade nos códigos para projetos de grandes proporções.

Já o *Spyder* é um ambiente de desenvolvimento gratuito escrito em *Python*, especialmente desenvolvido e projetado para cientistas, engenheiros e analistas de dados, oferecendo ferramentas de depuração de código, análise e edição avançada

de dados. Entre as principais ferramentas utilizadas, destaca-se o explorador de variáveis, que garante a observação e análise de informações coletadas de forma rápida e eficiente (SPYDER, 2022).

Dentre as principais bibliotecas da linguagem podemos citar o *Pandas*, ferramenta de análise e manipulação de dados construída em Python. (PANDAS, 2021). *Numpy*, biblioteca *Python* utilizada para cálculos em *arrays* multidimensionais, oferecendo uma grande quantidade de funcionalidades e operações para a execução de cálculos numéricos com grande facilidade. (SANTIAGO JUNIOR, 2018).

Para a construção dos modelos de *machine learning*, foi utilizado o *TensorFlow*, plataforma abrangente de código aberto para *machine learning*, desenvolvido pelo Google em 2015, possuindo diversas ferramentas, bibliotecas e recursos de sua comunidade que permite aos pesquisadores criar e implantar aplicativos com tecnologia de ML. (TENSORFLOW, 2021).

Já o *Keras* é parte central do *framework* do *TensorFlow* 2.0, sendo uma API desenvolvida adotando as melhores práticas para a simplificação e entendimento do seu funcionamento, minimizando o número de ações realizadas pelo usuário, indicando mensagens de erros claras e acionáveis, além de vasta documentação disponibilizada pelo desenvolvedor e comunidade (KERAS, 2021). Através da API do Keras, será criada e treinada a rede neural recorrente LSTM.

### 3.2 Coleta e tratamento de dados

Para a realização do estudo foram selecionadas 10 ações de empresas brasileiras listadas na B3, negociadas nos últimos 8 anos e três meses. A série histórica coletada de todos os ativos, inicia-se em 01-01-2013, terminando em 31-03-2022. Os seguintes fatores foram considerados para a escolha dos ativos:

- Liquidez média diária superior a 1 milhão de reais negociados diariamente;
- Histórico de negociação compatível, ou seja, todos os ativos foram negociados na bolsa durante o mesmo período;
- As empresas selecionadas atuam em setores distintos da economia (diversificação de mercado).



A seguir (Tabela 1) são listadas as dez ações que compõe a carteira de ativos a ser predito semanalmente pela rede neural LSTM, otimizado pela teoria moderna do portfólio.

Tabela 1 - Portfólio de ações

<b>Ticker</b>	<b>Empresa</b>	<b>Setor/subsetor</b>
SANB4	Banco Santander	Financeiro/Bancário
TAE11	Transmissora Aliança de Energia Elétrica	Energia/Transmissão
SAPR4	Companhia de Saneamento do Paraná (Sanepar)	Saneamento básico
FLRY3	Grupo Fleury	Saúde/ Serviços médicos, hospitalares, exames
VALE3	Vale SA	Materiais básicos/Mineração
LREN3	Lojas Renner	Consumo cíclico/Varejo
ROMI3	Indústrias Romi	Bens Industriais/ Máquinas e equipamentos industriais
ABEV3	Cervejaria Ambev	Consumo não cíclico/ Bebidas e refrigerantes
SULA11	Sul América Seguradora	Financeiro/Seguradoras
WEGE3	Wege SA	Máquinas e equipamentos/ Motores, compressores e outros

Fonte: Elaborado pelo autor (2021).

A série histórica coletada dos ativos foi dividida em três conjuntos de dados distintos, conjunto de treino, validação e teste (REGHIN, 2019; RUBIM, 2019), sendo 90% dos dados para treino e validação da rede neural e o restante (10%) para testes (MESQUITA, 2019; VASCO, 2020).

### 3.2.1 Tratamento da série histórica

Após a coleta da série histórica de cada uma das ações, foi realizado a remoção de dias faltantes no início e final da série histórica, além da técnica de interpolação linear a dados faltantes para o restante do conjunto de dados, assim como Mendonça (2019). Conforme Vieira (2014, p. 3), um método de interpolação linear "[...] se utiliza de uma função linear  $p(x)$  (um polinômio de primeiro grau) para representar, por aproximação, uma suposta função  $f(x)$  que originalmente representaria as imagens de um intervalo descontínuo (ou degenerado) contido no domínio de  $f(x)$ ".

Toda a série histórica de cada uma das ações foi ajustada para conter a mesma quantidade de dias negociados, além de ser mantido somente o preço de fechamento como variável de entrada para o treinamento da rede neural. No total 2295 dias de

negociação foram coletados, sendo 2047 dias utilizados para o treino e validação da rede neural, além de 248 dias (último ano de negociação) utilizado para simulação e testes da rede neural.

### 3.2.2 Normalização dos dados

Conforme adotado por Vasco (2020, p. 32), Dametto (2018, p. 50), Rubim (2019, p. 75) e Matsumoto (2019, p. 39), todos os dados da série histórica são normalizados para valores entre 0 e 1. Através da função *MinMaxScaler()* da biblioteca de *ML sklearn* do *Python* a normalização pode ser aplicada diretamente no *dataframe* correspondente a cada uma das ações. (VASCO, 2020).

A equação a seguir indica a forma de normalização utilizada por Vasco (2020) e Dametto (2018) em seus trabalhos de pesquisa, mesma forma utilizada neste trabalho de pesquisa. Sendo  **$x_{norm}$**  o valor final de normalização,  **$x$**  representa o valor corrente, ou original a ser normalizado,  **$x_{min}$**  e  **$x_{max}$**  representam, respectivamente, os valores máximos e mínimos do conjunto de dados a ser normalizado. (DAMETTO, 2018).

Equação 8 - Normalização dos dados

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Fonte: Vasco (2020, p. 32).

### 3.3 Modelagem da rede neural

Para Dametto (2020, p. 50), à luz de Weigend e Gershefel (1994), “[...] não é possível construir um algoritmo de predição que seja universal, isto é, que seja capaz de prever qualquer tipo de série temporal”. Pelo fato de a parametrização não ser um consenso entre diversos pesquisadores, tais parâmetros foram analisados e testados empiricamente no desenvolvimento deste trabalho de pesquisa, sendo adotada a técnica utilizada por Vasco (2020) para avaliação dos parâmetros, onde o EQM e EAM são analisados buscando-se o menor erro para a seleção dos parâmetros ótimos de cada um dos modelos de *machine learning* obtidos.

### 3.3.1 Número de camadas e neurônios

Vasco (2020), Rubim (2019) e Matsumoto (2019), realizaram diversos testes durante o processo de parametrização de seus modelos de ML, variando a quantidade de neurônios e camadas em suas RNAs, entre outros atributos. Para este trabalho, foi adotado a utilização de uma rede neural contendo 5 camadas de tamanhos iguais, variando entre 50 e 100 neurônios em cada camada, sendo a entrada e as camadas intermediárias do tipo *LSTM* e a camada de saída do tipo *Dense*.

### 3.3.2 Dropout

*Dropout* é um método de ajuste, ou regularização, onde as conexões de entrada das unidades recorrentes LSTM são aleatoriamente excluídas da ativação e atualização de pesos durante o processo de treinamento de uma rede tendo como objetivo reduzir o sobreajuste (*overfitting*), melhorando o desempenho do modelo. (BROWNLEE, 2017). Para este trabalho de pesquisa, utilizou-se as taxas de *dropout* de 10% e 15% para o treinamento das redes neurais.

### 3.3.3 Otimizadores e tamanho do lote

De acordo com Vasco (2020, p.35),

[...] otimizadores são algoritmos utilizados em redes neurais com o intuito de minimizar o erro, identificando os valores de peso ótimos a serem empregados na rede neural baseado nos dados de treinamento através do valor mínimo local da função.

ADAM é um método de otimização projetado especificamente para treinar redes neurais profundas, capaz de calcular a taxa de aprendizado individual de forma adaptativa para inúmeros parâmetros (RIBEIRO; ARAUJO JUNIOR, 2020). Pelo fato de o otimizador ADAM ter sido utilizado para o treino dos modelos de *machine learning* de diversos autores, como Vasco (2020), Dametto (2018), Rubim (2019) e Nelson (2017), foi o otimizador adotado para este trabalho de pesquisa.

O tamanho do lote é um parâmetro ajustável no aprendizado de máquina que define o tamanho de uma amostra do conjunto de dados que será treinado a cada

iteração (época) do modelo (DEEPLARNINGBOOK, 2021), isto é, caso selecionado um lote de tamanho 64, as primeiras 64 amostras do conjunto de dados serão passadas pela rede neural para treino do modelo (0-63) e assim, sucessivamente. Para este trabalho de pesquisa os lotes utilizados foram 8, 16, 32, e 64.

### 3.3.4 Número de épocas

O número de épocas é igual a quantidade de vezes que um conjunto de dados passa pelo processo de treino/aprendizado em uma rede neural sendo um parâmetro de extrema importância, uma vez que, quanto maior a quantidade de épocas utilizadas, mais a rede neural se adapta ao conjunto de dados, perdendo a capacidade de generalização. (VASCO, 2020). Para o treinamento da rede neural, o número de épocas foi variado entre 50 e 100.

### 3.3.5 Funções de ativação e tamanho da janela de treino

Para o desenvolvimento deste trabalho de pesquisa, optou-se pela utilização das funções de ativação tangente hiperbólica (*tanh*) e sigmóide, conforme utilizado por Matsumoto (2019), Dametto (2018) e Vasco (2020) em seus trabalhos de pesquisa. Desta forma, os modelos de *machine learning* serão construídos e avaliados, buscando-se o modelo que apresentar os melhores resultados através das métricas de menor EQM e EAM encontrado.

Conforme Matsumoto (2019, p. 38-39) sobre janelas de treino,

[...] janelas de visualização são a base necessária para transformar a série temporal dos dados em problemas de aprendizado supervisionado por regressão ou classificação, desde que a ordem das linhas seja preservada (ordem cronológica).

Matsumoto (2019), utiliza em seu estudo janelas de 1, 5, 10, 20, 24, 48 e 72 dias, representando, respectivamente, um dia, uma, duas e quatro semanas, um, dois e quatro meses, conforme dias úteis de negociação do mercado financeiro. Para este trabalho de pesquisa foi adotada uma janela de 5 dias para o treinamento e testes da rede neural.

### 3.4 Construção dos modelos de *machine learning*

Pelo fato da RNA poder apresentar inúmeras configurações distintas de entrada de parâmetros, sendo elas o número de camadas e neurônios, *dropout*, otimizadores, tamanho do lote, número de épocas, funções de ativação e tamanho da janela de treino, conforme citado ao longo do capítulo 3.3, foi desenvolvida uma tabela no *Microsoft Excel* contendo todas as combinações possíveis entre estes parâmetros para a importação e configuração da rede neural.

Desta forma, 64 combinações de parâmetros foram utilizadas para a configuração da rede neural, portanto, cada um dos ativos da carteira de investimentos foi treinado para cada uma das parametrizações, somando um total de 640 campanhas de treinamento para a rede neural LSTM, levando em consideração os dez ativos do portfólio. Ao final da fase de treino, o modelo de *machine learning* possuindo o menor EQM (VASCO, 2020) encontrado é salvo para a realização dos testes. A seguir é apresentado a parametrização que obteve o menor erro EQM para cada ativo do portfólio.

Quadro 1 - Parâmetros ótimos para cada ativo da carteira

Ticker	Janela	Neurônios	Ativação	Dropout	Otimizador	Perda	Épocas	Lotes	Erro
ABEV3	5	100	TANH	10%	ADAM	MSE	100	8	0,13
FLRY3	5	100	TANH	10%	ADAM	MSE	100	8	0,47
LREN3	5	100	TANH	10%	ADAM	MSE	100	16	2,01
ROMI3	5	100	TANH	10%	ADAM	MSE	100	32	0,18
SANB4	5	100	TANH	10%	ADAM	MSE	100	32	0,41
SAPR4	5	100	TANH	10%	ADAM	MSE	100	16	0,02
SULA11	5	100	TANH	10%	ADAM	MSE	100	8	1,53
TAE11	5	100	TANH	10%	ADAM	MSE	100	64	0,22
VALE3	5	100	TANH	10%	ADAM	MSE	100	32	2,36
WEGE3	5	100	TANH	15%	ADAM	MSE	100	8	0,57

Fonte: Elaborado pelo autor (2022).

## 4 RESULTADOS

Para a realização dos testes um novo programa desenvolvido em *python* foi criado. Através deste programa, os modelos de *machine learning* anteriormente treinados foram importados, além da série histórica do último ano de negociação de cada um dos ativos ser carregada (01/04/2021 à 31/03/2022, ou 248). A base histórica carregada para testes nunca passou pela rede neural durante a fase de treino e

validação, desta forma, busca-se simular fielmente a adoção de uma estratégia baseada em predição de dados futuras.

#### 4.1 Construção das carteiras de investimentos

No programa desenvolvido em *python* para testes, três carteiras de investimentos possuindo os mesmos ativos são construídas. A primeira carteira é ajustada de tal modo que, cada um dos ativos da possui o mesmo peso de capital alocado, neste caso 10% (*carteira\_pesos\_iguais*).

A segunda carteira (*carteira\_optima*) tem o peso dos seus ativos ajustados somente através da teoria moderna do portfólio, ou seja, como o período de testes já é conhecido (01/04/21 à 31/03/22), aplicando o modelo de Markowitz, obtemos a carteira mais eficiente para esta série histórica utilizada.

Antes de obter a carteira mais eficiente, algumas regras foram adotadas, com o objetivo de manter ao máximo a diversificação de ativos investidos na carteira. Para todos os ativos, um peso mínimo e máximo foi definido, fixado entre 3,5% e 15%. Dez mil portfólios, ou combinações de pesos foram gerados, sendo que, ao final da simulação, somente 442 carteiras respeitaram as regras de pesos definidas. Destas 442 carteiras, o portfólio mais eficiente encontrado, respeitando a relação retorno/risco, obteve um retorno de -5,3%, volatilidade (risco) de 17,2.

Quadro 2 - Melhor Sharpe Ratio (Teoria do Portfólio)

Ativos	Pesos / Valores retornados	Ativos	Pesos / Valores retornados
SANB4.SA	14,3%	LREN3.SA	3,5%
TAEE11.SA	14,2%	ROMI3.SA	4,7%
SAPR4.SA	13%	ABEV3.SA	10%
FLRY3.SA	5,2%	SULA11.SA	10,3%
VALE3.SA	14,1%	WEGE3.SA	10,7%

Fonte: Elaborado pelo autor (2022).

A terceira carteira de investimentos (*carteira\_predição*) é obtida através da predição dos retornos semanais futuros, dado pelos modelos de *machine learning* de cada um dos ativos do portfólio. Assim, aplicando a teoria de Markowitz, os pesos de cada um dos ativos da carteira são ajustados para a semana futura predita, obtendo-

se uma carteira de investimentos otimizada, onde o maior retorno é obtido, buscando-se o menor risco aceitável.

Os pesos retornados semanalmente pelo modelo de Markowitz para a *carteira\_predição*, seguem as mesmas regras definidas de obtenção de alocação de capital da carteira mais eficiente (*carteira\_optima*), desta forma, facilitasse a avaliação entre os portfólios analisados.

## **4.2 Avaliação das carteiras de investimentos**

Conforme indicado através da Equação 2 (p. 7), o retorno sobre o investimento permitirá obtermos a rentabilidade da cesta de ativos durante o último ano de negociação, sendo possível a análise e comparação deste retorno entre as carteiras estudadas. A volatilidade, apresentada através da Equação 3 (p. 7), indicará o quanto a rentabilidade sobre o investimento variou durante o último ano de negociação, isto é, o risco assumido para a estratégia de investimentos adotada.

### **4.2.1 Taxa de retorno anual das carteiras de investimentos**

O Gráfico 1 (p. 22), ilustra o desempenho obtido para as três carteiras de investimentos estudadas, além de proporcionar, visualmente, uma análise rápida sobre o desempenho e comportamento de cada um dos portfólios durante o último ano de negociações.

Gráfico 1 - Comparação entre as carteiras estudadas



Fonte: Elaborado pelo autor (2022).

Comparando os retornos obtidos entre as três carteiras de investimentos analisadas, observou-se que a *carteira\_optima* obteve o melhor desempenho ou maior retorno. Já a carteira que obteve o pior desempenho foi a *carteira\_predição*. A seguir, são apresentados os resultados obtidos aplicando-se os cálculos de retorno de um portfólio de ativos, apresentados através da Equação 2 (p. 7).

Quadro 3 - Retorno anual das carteiras de investimentos

Carteira	Retorno anual (%)
Carteira_Optima	-5.3 %
Carteira_Pesos_Iguais	-12.1 %
Carteira_Predição	-16.8 %

Fonte: Elaborado pelo autor (2022).

#### 4.2.2 Volatilidade das carteiras de investimentos

Analisando o Gráfico 1 (p. 22) podemos observar que todas as carteiras possuem um grau de volatilidade relativamente parecidos, porém, ao aplicarmos os cálculos para obter a volatilidade dos portfólios, conforme Equação 3 (p. 7), verificamos que *carteira\_optima*, novamente, apresenta o melhor desempenho, isto é, menor volatilidade ou risco. A maior volatilidade encontrada está atribuída a *carteira\_predição*. Os resultados são mostrados a seguir (Quadro 4, p. 23).



Quadro 4 - Volatilidade das carteiras de investimentos

Carteira	Volatilidade anual (%)
Carteira_Optima	17.2 %
Carteira_Pesos_Iguais	19.2 %
Carteira_Predição	22.7 %

Fonte: Elaborado pelo autor (2022).

## 5 ANÁLISE DE RESULTADOS

### 5.1 Analisando as estratégias de investimento

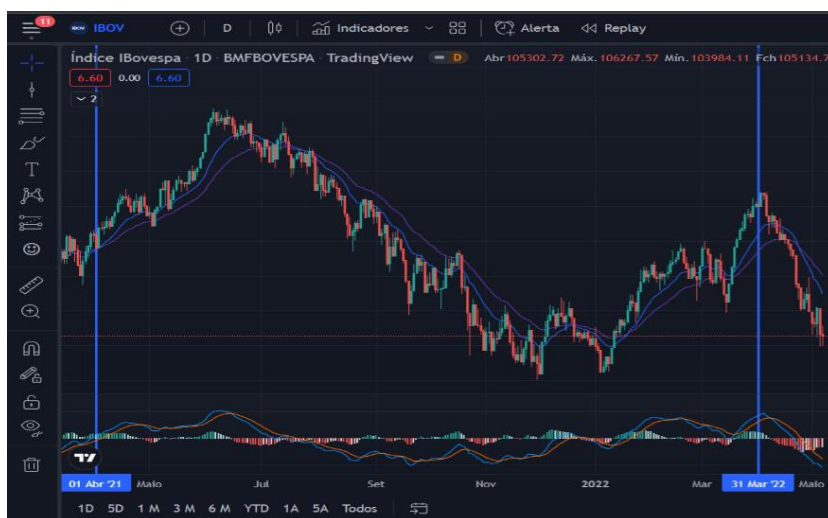
Com relação ao retorno da *carteira\_optima* (-5,3%), seu resultado superior em comparação com as outras duas carteiras analisadas já era esperado, uma vez que, a sua construção levou em consideração um período de negociação passado, conforme explicado no capítulo 4.1. Assim, a *carteira\_optima* serve como um modelo para avaliarmos o desempenho das outras estratégias de investimentos estudadas, *carteira\_predição* e *carteira\_pesos\_iguais*.

Ao observarmos o retorno obtido pela *carteira\_predição* (-16,8%) em relação a *carteira\_pesos\_iguais* (-12,1%), esperava-se que a carteira predita apresentasse o maior retorno e menor risco, se aproximando do obtido para a *carteira\_optima*, já que a predição dos preços futuros era almejada, porém o resultado foi o oposto. A *carteira\_pesos\_iguais*, seguindo uma estratégia simples de investimento, de fácil adesão por parte dos investidores, obteve um retorno superior em cerca de 4,7%.

Ao observarmos o Gráfico 1 (p. 22), podemos notar que até a aproximadamente o 180º dia de negociação, a rentabilidade entre todas as carteiras estudadas era próxima (-19,3%, -15,7% e -18,3 para *iguais*, *ótima* e *predição*, respectivamente), porém a partir desta data, a rentabilidade entre as carteiras começa a apresentar um comportamento mais volátil nos preços, coincidindo com o fim do ciclo de baixa observado no mercado acionário.

Isso pode ser explicado observando-se o comportamento do mercado acionário brasileiro para o mesmo período em que as carteiras foram simuladas através do gráfico do Ibovespa indicado a seguir (Gráfico 2, p. 24). Podemos observar que o mercado de ações apresentou cerca de 4 meses de forte queda nas cotações desde o último pico de preços alcançado na metade de maio de 2021, penalizando o retorno das ações, retomando a tendência de alta, aproximadamente no início do ano de 2022.

Gráfico 2 - Retorno Ibovespa entre 01/04/21 e 31/03/22



Fonte: Elaborado pelo autor (2022).

Após o término da tendência de baixa observado no mercado, os modelos de *machine learning* utilizados para a *carteira\_predição*, não conseguiram explicar de forma assertiva o comportamento das ações durante a retomada da tendência de alta do mercado, desta forma, o ajuste de pesos semanal, dado pela teoria do portfólio não foi mais preciso, ocasionando a perda da rentabilidade durante a período de alta.

O mesmo não pode ser dito para a *carteira\_pesos\_iguais*, uma vez que, a alocação de capital igualmente distribuída entre os ativos, durante o período de retomada da tendência de alta no mercado, ocasionou menor volatilidade na carteira (Quadro 5), proporcionando um maior retorno até o fim do período de testes.

Quadro 5 - Volatilidade após a retomada do ciclo de alta do mercado

Carteira	Risco/Volatilidade
Carteira_optima	17,2%
Carteira_pesos_iguais	19,2%
Carteira_predição	24,2%

Fonte: Elaborado pelo autor (2022).

## 6 CONSIDERAÇÕES FINAIS

Diante dos testes realizados, bem como, dos resultados obtidos para as estratégias de investimentos analisadas, verificou-se pouca efetividade em se aplicar a teoria do portfólio para dados preditos semanalmente através de modelos de ML treinados a partir da série histórica de ativos compondo uma carteira de investimentos.

Do ponto de vista prático para o investidor comum, a alocação de capital igual entre todos os ativos de sua carteira seria o suficiente para lhe conferir uma relação retorno/risco aceitável, não sendo necessário utilizar a análise de dados, bem como a construção de modelos de *machine learning* complexos.

Mesmo que a estratégia de predição não tenha superado a alocação de capital igual entre os ativos de um portfólio no longo prazo ou fim da série histórica, conforme demonstrado no capítulo 5.1.1, aproximadamente até o 180º dia de negociação, a estratégia de predição apresentava bons resultados, próximos a *carteira\_optima*, sugerindo que até este ponto no tempo a estratégia de predição, aliada a alocação eficiente de capital dada pelo modelo de Markowitz, funcionara.

Desta forma, sugere-se que mais trabalhos de pesquisa, adotando a estratégia de predição aliada ao modelo de Markowitz, devem ser conduzidos, buscando-se o desenvolvimento de RNAs mais adaptativas aos ciclos do mercado, não levando em consideração somente a métrica de EQM e MSE utilizadas nos ciclos de treinamento da RNA. Assim busca-se preparar a rede neural para as mudanças de comportamento do mercado acionário ocasionadas pelos mais diversos eventos, melhorando a efetividade das predições e consequentemente o correto ajuste dos pesos dos ativos.

Ainda, durante o processo de construção dos modelos de ML, verificou-se poucos ativos em negociação na bolsa do Brasil que apresentam uma base histórica mais extensa e de qualidade, isto é, sem a presença de dias de negociação faltantes. Assim, a falta de séries históricas mais extensas utilizadas na fase de treinamento dos modelos podem ter prejudicado sua capacidade de aprendizado, uma vez que, um período muito curto de negociação do mercado acionário foi consumido.

Como alternativa para a pouca base histórica disponível para os ativos na bolsa do Brasil, propõe-se a coleta de dados de ações do mercado acionário norte-americano, pois, conforme Castro (2021), somente a bolsa de valores de Nova York (NYSE) fundada em 1792, movimenta cerca de US\$ 20 trilhões, ou 14 vezes o PIB do Brasil, concentrando aproximadamente 3000 empresas, entre elas, Coca-Cola (KO), Berkshire Hathaway (BRK) e Johnson & Johnson (JNJ).

Levando em consideração a modelagem da RNA LSTM apresentada neste trabalho, bem como a limitação de processamento de dados para a realização do treinamento da rede neural, optou-se por um máximo de 64 configurações possíveis de variáveis para os mais diversos parâmetros, conforme apresentado no capítulo 3.3.

Isto ocorre pelo fato de que, a cada nova variável adicionada para treinamento, as combinações possíveis de parâmetros dobram. Assim, a inserção de 3 novas variáveis seria o suficiente para elevar de 64 para 512 combinações de parâmetros, resultando em 5120 campanhas de treinamentos, levando em consideração os 10 ativos da carteira de ações hipotéticas.

Desta forma, evidencia-se uma grande dificuldade no que diz respeito ao acesso a meios de processamento de dados adequados a tarefas de treinamento mais extensas, evidenciando o não acesso a este tipo de recurso por boa parte dos investidores. Neste sentido a adoção de projetos de computação distribuída podem ser de grande valia, uma vez que, possibilita a distribuição do processamento entre diversos computadores de uma rede, permitindo a repartição de tarefas computacionais de acordo com a natureza e função de cada computador. (SIMON, 1997).

## REFERÊNCIAS

AGUILLAR, Beatriz. Como montar uma carteira de investimento? *In*: Clear. São Paulo, 23 nov. 2020. Disponível em: <https://master.clear.com.br/blog/como-montar-uma-carteira-de-investimentos/>. Acesso em: 13 maio 2021.

AZEVEDO, Débora; MACHADO, Lisiane; SILVA, L. V. **Métodos e procedimentos de pesquisa**: do projeto ao relatório final. São Leopoldo: Unisinos, 2011.

B3. Institucional. São Paulo, [2021?]. Disponível em: [https://www.b3.com.br/pt\\_br/b3/institucional/quem-somos/](https://www.b3.com.br/pt_br/b3/institucional/quem-somos/). Acesso em: 27 abr. 2021.

BRAGA, Antonio de Pádua; LUDERMIR, Teresa Bernarda; CARVALHO, André Carlos Ponce de Leon Ferreira. **Redes neurais artificiais**: teoria e aplicações. Rio de Janeiro: Ed. LTC, 2000.

BROWNLEE, Jason. Dropout with LSTM Networks for Time Series Forecasting. *In*: Machine Learning Mastery. [S.l], 2017. Disponível em: <https://machinelearningmastery.com/use-dropout-lstm-networks-time-series-forecasting/>. Acesso em: 17 jun. 2021.

CASTRO, Johnatan. Nasdaq e NYSE: conheça as bolsas americanas. *In*: Nubank. São Paulo, 10 nov. 2021. Disponível em: <https://blog.nubank.com.br/nasdaq-nyse-bolsa-americana/>. Acesso em: 09 maio 2022.

COSTA, Alexandres Dias da. **A relação entre os indicadores contábeis e o retorno das ações no mercado brasileiro**. 2015. 82 p. Dissertação (Mestrado em

Administração) – Programa de Pós-Graduação em Administração, Fundação Escola de Comércio Álvares Penteado, São Paulo, 2015.

DAMETTO, Ronaldo César. **Estudo da aplicação de redes neurais artificiais para predição de séries temporais financeiras**. 2018. 66 p. Dissertação (Mestrado em Engenharia de Produção) – Programa de Pós-Graduação em Engenharia da Produção, Universidade Estadual Paulista “Júlio de Mesquita Filho”, Bauru, 2018.

DEEPLARNINGBOOK. **Capítulo 37** – O efeito do Batch Size no treinamento de redes neurais artificiais. [S.l, 2021?]. Disponível em: <https://www.deeplearningbook.com.br/o-efeito-do-batch-size-no-treinamento-de-redes-neurais-artificiais/>. Acesso em: 20 jun. 2021.

ELLER, Vitor Grando. **Aplicação de redes neurais e fatores de prêmio de risco no mercado de ações**. 2020. 23 p. Trabalho de Conclusão de Curso (Bacharel em Engenharia de Produção) – Curso de Engenharia de Produção, Instituto de Ensino Insper, São Paulo, 2020.

GIL, Antonio Carlos. **Como elaborar projetos de pesquisa**. 4. ed. São Paulo: Atlas, 2007.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. **Deep Learning**. [S.l.]: MIT Press, 2016.

GOMES, Dennis dos Santos. Inteligência Artificial: Conceitos e Aplicações. **Revista Olhar Científico**, Ariquemes, v. 1, n. 2, p. 234-246, ago./dez. 2010.

HAYKIN, Simon S. **Neural Networks and Learning Machines**. 3. ed. New Jersey: Pearson Prentice Hall, 2008.

IGARASHI, Wagner; MARTIOLI, Lucas Fernando; IGARASHI, Deisy Cristina Corrêa. Econometria e inteligência artificial: criação de portfólio de ações rentáveis. **Braz. J. of Develop.**, Curitiba, v. 5, n. 6, p. 4356-4371, jun. 2019.

INFOMONEY. Entenda como funciona o mercado de ações e a bolsa de valores. São Paulo, [2021?]. Disponível em: <https://www.infomoney.com.br/guias/mercado-de-acoes/>. Acesso em: 27 abr. 2021.

KERAS. Disponível em: <https://keras.io/>. Acesso em: 13 jun. 2021.

KERR, Roberto B. **Mercado Financeiro e de Capitais**. São Paulo: Pearson Prentice Hall, 2011.

LEITE, Douglas. Teoria Moderna do Portfólio. *In*: Liga de Mercado Financeiro FEA-USP. São Paulo, 21 maio 2020. Disponível em: <https://www.ligafeausp.com/single-post/2020/05/21/teoria-moderna-do-portf%C3%B3lio>. Acesso em: 17 maio 2021.

LUND, Myrian Layr Monteiro Pereira; SOUZA, Cristóvão Pereira de; CARVALHO, Luiz Celso Silva de. **Mercado de capitais**. Rio de Janeiro: Editora FGV, 2014. *E-book*.

MARKOWITZ, Harry. Portfolio selection. **The Journal of Finance**, [S.l.], v. 7, n. 1, p. 77-92, mar. 1952.

MARTINS, Marco Antônio dos Santos; METTE, Frederike; MACEDO, Guilherme Ribeiro. A utilização das redes neurais artificiais para a estimação dos preços da Petrobrás PN na Bovespa. **ConTexto**, Porto Alegre, v. 8, n. 14, p. 1-16, 2. sem. 2008.

MASI, Nathalia Virginia; LOPES, Célia Mendes Carvalho. Estudo de modelo de séries temporais para dados de ações. *In*: SIMPOSIO NACIONAL DE PROBABILIDADE E ESTATÍSTICA, 19., 2009, São Pedro. **Anais eletrônicos...** Campinas: Unicamp, 2009.

MATSUMOTO, Daniel Kazuyuki Fuggi. **Estudo em séries temporais financeiras utilizando redes neurais recorrentes**. 2019. 42 p. Dissertação (Mestrado em Modelagem Computacional do Conhecimento) – Programa de Pós-Graduação em Modelagem Computacional do Conhecimento, Universidade Federal de Alagoas, Maceió, 2019.

MEDEIROS, Claudimaicon Nunes. **Avaliação de técnicas de redes neurais para previsão de preços no mercado de Boi Gordo**. 2019. 48 p. Trabalho de Conclusão de Curso (Bacharelado em Engenharia de Computação) – Curso de Engenharia de Computação, Instituto Federal de Educação, Ciência e Tecnologia, Bambuí, 2019.

MENDONÇA, Guilherme Góes. **Redes neurais artificiais na predição do preço de ações**. 2019. 115 p. Trabalho de Conclusão de Curso (Bacharel em Engenharia Eletrônica) – Curso de Engenharia Eletrônica, Universidade Federal de Santa Catarina, Florianópolis, 2019.

MESQUITA, Caio Mário Henriques Silva da Rocha. **Ciência de dados e aprendizado de máquina para predição em séries temporais financeiras**. 2019. 131 p. Dissertação (Mestrado em Ciência da Computação) – Programa de Pós-Graduação em Ciência da Computação, Universidade Federal de Minas Gerais, Belo Horizonte, 2019.

MOTA, Pedro Lula. Markowitz e a Teoria Moderna de Portfólios. *In*: Terraço Econômico. [S.l.], 13 dez. 2017. Disponível em: <https://terracoeconomico.com.br/markowitz-e-teoria-moderna-de-portfolios/>. Acesso em: 17 maio 2021.

NELSON, David Michael Quirino. **Uso de redes neurais recorrentes para previsão de séries temporais financeiras**. 2017. 73 p. Dissertação (Mestrado em Ciência da Computação) – Programa de Pós-Graduação em Ciência da Computação, Universidade Federal de Minas Gerais, Belo Horizonte, 2017.

OLIVEIRA, Marcelo. Neuronios. *In*: Infoescola, [S.l., 2021?]. Disponível em: <https://www.infoescola.com/sistema-nervoso/neuronios/>. Acesso em: 22 maio 2021.

PANDAS. Disponível em: <https://pandas.pydata.org/>. Acesso em: 13 jun. 2021.

PASSOS, Luiz Otávio de Medeiros Portella. **Uso de redes neurais recorrentes para previsão na Bovespa**. 2020. 75 p. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Curso de Ciências da Computação, Universidade Federal de São Paulo, 2020.

PEREIRA, Ricardo. A melhor estratégia para montar uma carteira de investimentos. *In: Dinheirama*. [S.l.], 2018. Disponível em: <https://dinheirama.com/a-melhor-estrategia-para-montar-uma-carteira-de-investimentos/>. Acesso em: 13 maio 2021.

REGHIN, Daniel. **Previsão de Value-at-Risk para o mercado brasileiro**: Um estudo comparativo entre o método paramétrico, redes neurais artificiais Feedforward e Long Short-Term Memory. 2019. 124 p. Dissertação (Mestrado em Engenharia de Computação) – Programação de Pós-Graduação em Engenharia da Computação, Instituto de Pesquisas Tecnológicas do Estado de São Paulo, São Paulo, 2019.

RIBEIRO, Athyrson M.; ARAUJO JUNIOR, Francisco de Paula S. Um estudo comparativo entre cinco métodos de otimização aplicados em uma RNC voltada ao diagnóstico do glaucoma. **Revista de Sistemas e Computação**, Salvador, v. 10, n. 1, p. 122-130, jan./abr. 2020.

ROMANI, Lucas Flasch. **Aplicação de redes neurais artificiais na sugestão de investimentos**. 2017. 94 p. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Curso de Ciência da Computação, Universidade Brasília, Brasília, 2017.

ROVEDA, Ugo. O que é Python, para que serve e por que aprender? *In: Kenzie Academy*. Curitiba, 13 out. 2020. Disponível em: <https://kenzie.com.br/blog/o-que-e-python/>. Acesso em: 13 jun. 2021.

RUBIM, Felipe Henrique. **Deep Learning no mercado acionário brasileiro**: fatores que possibilitam previsões consistentes para a tomada de decisão em condições de risco. Dissertação (Mestrado em Ciências) – Programa de Pós-Graduação em Administração, Universidade de São Paulo, São Paulo, 2019.

SANTANA, Renato Elias; DANTAS, Maria José Pereira; LOIOLA, Rafael Gomes. Aplicação de redes neurais para a predição no mercado de ações nacional. *In: SIMPÓSIO BRASILEIRO DE PESQUISA OPERACIONAL*, 48., 2016, Vitória. **Anais eletrônicos...** Rio de Janeiro: SOBRAPO, 2016.

SANTIAGO JUNIOR, Luiz. Entendendo a biblioteca NumPY. *In: Ensina aí*. [S.l.], 30 set. 2018. Disponível em: <https://medium.com/ensina-ai/entendendo-a-biblioteca-numpy-4858fde63355>. Acesso em: 13 jun. 2021.

SILVA, Rafael Ribeiro da. **Deep Learning aplicado à predição de tendências no mercado de ações**. 2018. 58 p. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Curso de Ciência da Computação, Universidade Estadual do Norte do Paraná, Bandeirantes, 2018.

SIMON, Imre. Computação distribuída. *In*: Instituto de Matemática e Estatística. São Paulo, 1997. Disponível em: <https://www.ime.usp.br/~is/abc/abc/node12.html>. Acesso em: 11 maio 2022.

SOARES, Pablo; SILVA, José Patrocínio da. Aplicação de redes neurais artificiais em conjunto com o método vetorial da propagação de feixes na análise de um acoplador direcional baseado em fibra ótica. **Revista Brasileira de Computação Aplicada**, Passo Fundo, v. 3, n. 2, p. 58-72, set. 2011.

SPYDER. Disponível em: <https://www.spyder-ide.org/>. Acesso em: 06 maio 2022.

TENSORFLOW. Porque usar o TensorFlow. Disponível em: <https://www.tensorflow.org/?hl=pt-br>. Acesso em: 13 jun. 2021.

THIELE, Cássio Cristiano. **Combinando sistemas especialistas na previsão de séries temporais financeiras**. 2015. 90 p. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Curso de Ciência da Computação, Universidade de Caxias do Sul, Caxias do Sul, 2015.

VASCO, Lucas Pimenta. **Um estudo de redes neurais recorrentes no contexto de previsões no mercado financeiro**. 2020. 49 p. Trabalho de Conclusão de Curso (Bacharel em Engenharia da Computação) – Curso de Engenharia da Computação, Universidade Federal São Carlos, São Carlos, 2020.

VIEIRA, Thales. **Interpolação**. Maceió: Universidade Federal de Alagoas, 2014. Disponível em: <https://ic.ufal.br/professor/thales/icg/Aula1.2.pdf>. Acesso em: 19 jun. 2021.

VILELA, Eunice Henriques Pereira; PENEDO, Antonio Sergio Torres; PEREIRA, Vinícius Silva. Aplicação de redes neurais artificiais na predição de preços de ações por indicadores financeiros. **Desafio Online**, Campo Grande, v.6, n.2, p. 323-344, maio/ago. 2018.